

Análisis de datos

Carrera de Especialización en
Inteligencia Artificial
B5 2025



Programa de la materia

1

Introducción al análisis de datos

23/10

Flujo de trabajo típico. Aplicaciones. Configuración del entorno. Introducción a las principales bibliotecas. Introducción al EDA.

2

Análisis exploratorio de datos (EDA)

30/10

EDA. Estadística robusta. Visualización de variables numéricas y categóricas. Relación entre variables. Data cleaning y data wrangling. Identificación de valores faltantes y outliers.

3

Taller práctico - parte 1

6/11

Práctica en salas virtuales: EDA y visualización inicial de un dataset. Buenas prácticas. Puesta en común.

4

Preprocesamiento y limpieza de datos

13/11

Presentación de grupos de trabajo final. Prevención de data leakage. Tratamiento de datos faltantes. Tratamiento de outliers.

5

Feature engineering

20/11

Cardinalidad, codificación, discretización. Desbalance. Creación de nuevos features. Normalización y estandarización.

6

Reducción de dimensionalidad

27/11

Métodos de extracción y técnicas para selección de features. **Bonus:** EDA de datos no estructurados.

7

Taller práctico - parte 2

4/12

Práctica en salas virtuales: preprocesamiento y feature engineering de un dataset. Puesta en común. **Bonus:** Herramientas para automatizar el EDA.



Martes 9/12 - límite para compartir el material para la exposición final.

8

Exposición final

11/12

Exposición de trabajos finales (desdoblada en 2 sesiones, 11/12 y 15/12).

Breve repaso de la clase anterior y espacio para consultas



Tipos de variables

Cosas que puedo medir

Cuantitativas (numéricas)

Discretas

Toman valores enteros

Cantidad de hijos

Número de visitas al médico

Número de ventas

Continuas

Pueden tomar cualquier valor dentro de un rango

Temperatura

Altura

Edad

Cualidades/características

Categóricas (cualitativas o atributos)

Nominales

Sin orden

Estado civil

Nombre de ciudad

Día de la semana

Ordinales

Tienen un orden específico (jerarquía o magnitud)

Talles de ropa (S, M, L)

Opiniones (muy de acuerdo, de acuerdo,...)

Nivel de educación (secundario, terciario, universitario)

Tipos de variables: consideraciones

- Una variable categórica se puede representar con números (que actúan como un encoding).
- La **edad** en general se considera una variable continua pero generalmente se mide y reporta como discreta (Ej., en años). → Naturaleza de los datos vs. cómo se refleja.
- Las variables **binarias** (Sí/No, 1/0, True/False) son un caso particular de las categóricas nominales.
- Las **fechas** tienen una doble naturaleza:
 - Numérica, cuando interesa medir tiempo transcurrido o tendencias.
 - Categórica, cuando interesa agrupar eventos en una fecha específica (Ej., analizar las ventas en un día particular de la semana).
- ¿Qué pasa con las **coordenadas geográficas**?



Estadística descriptiva



- Las métricas descriptivas permiten estimar las características de una variable aleatoria utilizando una muestra de datos.
- La distribución de **datos numéricos** se puede caracterizar en términos de su **tendencia central**, su variabilidad (**dispersión**) y su **forma**.
- Los **datos categóricos** se pueden describir a partir de cantidades, proporciones y porcentajes de los distintos valores o categorías.

Momentos

Los momentos son medidas que capturan diferentes aspectos de una distribución de datos.

Momento de orden k
(calculado respecto al origen)

$$\mu'_k = \frac{1}{n} \sum_{i=1}^n x_i^k$$

Momento central de orden k
(calculado respecto a la media)

$$\mu_k = \frac{1}{n} \sum_{i=1}^n \left(x_i - \bar{x} \right)^k$$

1. Exploración de datos numéricos



Tendencia central

- 1 MEDIA
- 2 MEDIANA
- 3 MODA

Dispersión

- 4 VARIANZA
- 5 DESVIACIÓN ESTÁNDAR
- 6 CUARTILES Y RANGO INTERCUARTIL

Forma

- 7 SKEWNESS
- 8 CURTOSIS




Actividad VARIABLES NUMÉRICAS

cuestionario



Tendencia central: media, mediana y moda

Son distintas formas de medir el
"centro" en un conjunto numérico de
datos.



Media, mediana y moda: ejemplo

Ejemplo (notas de alumnos): {9, 9, 8, 9, 10, 5}

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\text{Media} = \frac{9+9+8+9+10+5}{6} = 8,33$$

Representa la nota si todos se hubieran sacado lo mismo

Mediana = valor del medio de una lista ordenada

$$\text{Mediana} = \{5, 8, \underbrace{9, 9}, 9, 10\}$$

(Media de los dos valores del centro por ser cantidad par)

La nota del medio. Una mitad de la clase sacó menos de 9 y la otra mitad, más que 9.

Moda = el valor más frecuente

$$\text{Moda} = \{\underbrace{9, 9}, 8, 9, 10, 5\}$$

Puede o no haber moda. Puede haber más de una (bimodal, trimodal, multimodal).


La nota más frecuente fue 9.

Medidas de dispersión: varianza y desviación estándar

- Sirven para medir qué tan “desparramados” están los datos alrededor de la media.
- La desviación estándar suele ser más fácil de interpretar.

$$\sigma^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2$$


$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2}$$



Varianza y desviación estándar - ej.

$$C1 = \{-10, 0, 10, 20, 30\}$$

$$C2 = \{8, 9, 10, 11, 12\}$$



$$\bar{\mu}_1 = \frac{-10+0+10+20+30}{5} = 10$$

$$\bar{\mu}_2 = \frac{8+9+10+11+12}{5} = 10$$

$$\sigma_1^2 = \frac{(-10-10)^2 + (0-10)^2 + (10-10)^2 + (20-10)^2 + (30-10)^2}{4}$$

$$\sigma_2^2 = \frac{(8-10)^2 + (9-10)^2 + (10-10)^2 + (11-10)^2 + (12-10)^2}{4}$$

$$\sigma_1^2 = 250$$

$$\sigma_2^2 = 2,5$$

$$\sigma_1 = \sqrt{\sigma_1^2} = \sqrt{250} = 15,8$$

$$\sigma_2 = \sqrt{\sigma_2^2} = \sqrt{2,5} = 1,58$$

Cuantiles

- Son valores que dividen un conjunto de datos **ordenados** en partes iguales.
- Se usan para analizar la distribución de los datos.
- Tipos de cuantiles más comunes:
 - **Cuartiles:** dividen los datos en 4 partes iguales.
 - **Deciles:** dividen los datos en 10 partes iguales.
 - **Percentiles:** dividen los datos en 100 partes.



Cuartiles

- Q1 o primer cuartil o cuartil inferior: el 25% de los datos son menores o iguales a él.
- Q2 o segundo cuartil: es el valor que divide al conjunto en dos mitades iguales.
- Q3 o tercer cuartil o cuartil superior: El 75% de los datos son menores o iguales a él.


En términos de la función de distribución acumulada (CDF):

- Q1 es el valor x tal que $F(x) = P(X \leq x) = 0,25$
- Q2 es el valor tal que $F(x) = P(X \leq x) = 0,50$
- Q3 es el valor tal que $F(x) = P(X \leq x) = 0,75$



Rango intercuartil (IQR)

El IQR mide la dispersión del 50% central de los datos.




- IQR pequeño → centro de datos concentrado.
- IQR grande → centro de datos disperso.

El IQR se considera pequeño si es menor al 10%-20% del rango total (máx - mín).


Cuartiles y rango intercuartil - Ejemplo

Datos: {4, 4, 10, 11, 15, 7, 14, 12, 6}



Medidas de forma: asimetría y curtosis




- Se usan para describir la forma y comportamiento de una distribución de datos.
- Permiten detectar si se desvían de la "normalidad".
- Ayudan a evaluar patrones no evidentes (sesgos, outliers) que no se detectan con medias o desviaciones estándar.
- Se utilizan para distribuciones continuas.



Asimetría (Skewness)

- Es una medida de la simetría de la distribución de los datos con respecto al valor central.
- Los datos reales casi siempre presentan asimetría.
- En casos de asimetría, la media deja de ser una buena representación del centro.

$$Asimetria = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^3}{\sigma^3}$$



Reglas para evaluar la asimetría

- Entre -0,5 y 0,5 se considera aproximadamente simétrica.
- Entre -1 y -0,5 ó entre 0,5 y +1 se considera moderadamente asimétrica.
- Menor que -1 ó mayor que +1 se considera altamente asimétrica.



Curtosis

- Es una medida del peso de las "colas" de la distribución (cuántos datos hay hacia los extremos).
- Para una distribución Normal estándar, la curtosis es 3.

$$Curtosis = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^4}{\sigma^4}$$



Curtosis exceso

- La curtosis exceso es igual a la curtosis menos 3. Sirve para comparar la curtosis de los datos con la una distribución normal.
- Una curtosis exceso positiva puede indicar muchos datos en las colas y, por ende, la presencia de outliers.

Evaluación de la curtosis

Convención para la curtosis exceso:

- Cerca de 0: "mesocúrtica", se considera Normal.
- Mayor que 0: "leptocúrtica" (colas pesadas) -->¿outliers?
- Menor que 0: "platicúrtica" (colas menos pesadas)




En este ejemplo:

- Distribución de Laplace con $\mu = \frac{1}{\sqrt{2}}$
- Normal estándar $\mu = 0, \sigma^2 = 1$
- Uniforme entre $\pm\sqrt{3}$


*Fuente

Visualización de datos numéricos

HISTOGRAMA




Kernel Density Estimation (KDE)




BOXPLOT

Pasajeros del Titanic



Pasajeros del Titanic

VIOLIN PLOT



2. Exploración de datos categóricos



Concentración de categorías

- 1 MODA
- 2 PROPORCIÓN DE LA MODA
- 3 MULTIMODALIDAD


Distribución y frecuencia

- 4 FRECUENCIA ABSOLUTA
- 5 FRECUENCIA RELATIVA
- 6 RANGO DE FRECUENCIAS

Diversidad o variabilidad


- 7 CARDINALIDAD
- 8 ENTROPÍA DE SHANNON

Actividad VARIABLES CATEGÓRICAS



Medidas de concentración de categorías

1. **Moda:** valor más frecuente
2. **Proporción de la moda:** qué proporción del total está representado por la moda.
3. **Multimodalidad:** permite detectar si la distribución está dominada por una sola categoría.



categoría	cantidad
cat.1	5
cat.2	10
cat.3	15
cat.4	10
cat.5	5


moda

Medidas de distribución y frecuencia

4. **Frecuencia absoluta.** número de veces que aparece cada categoría.

5. **Frecuencia relativa.** Proporción de cada categoría respecto al total de observaciones.

6. **Rango de frecuencias.** diferencia entre la categoría más frecuente y la menos frecuente.



categoría	cantidad
cat.1	5
cat.2	10
cat.3	15
cat.4	10
cat.5	5

Entropía de Shannon

La incertidumbre de Shannon o entropía de Shannon mide la incertidumbre o diversidad asociada a una fuente de información.

$$H(X) = - \sum_{i=1}^n p_i \log_2 p_i$$

p_i : proporción de la categoría i
(frecuencia relativa de la categoría).
 n : número de categorías (**cardinalidad**)


En variables categóricas, la entropía mide cuán dispersa o uniforme es la distribución de frecuencias.

- **Mayor entropía** → más incertidumbre sobre a qué categoría pertenece una observación elegida al azar. Las categorías están equilibradas o bien distribuidas.
- **Menor entropía** → hay poca incertidumbre. Una o pocas categorías dominan al resto.
- **Entropía máxima** → Para n categorías, la entropía máxima es $\log_2(n)$. Se da cuando todas las categorías son igualmente probables.

Visualización de datos categóricos

Para complementar las métricas, es recomendable usar diferentes visualizaciones

Gráfico 15. Mujeres en viviendas particulares de 14 a 49 años con hijas e hijos nacidos vivos en el último año que asistieron a un establecimiento educativo, por cada mil mujeres, según máximo nivel educativo alcanzado. Año 2022




Fuente: INDEC, Censo Nacional de Población, Hogares y Viviendas 2022. Resultados definitivos.

Fuente: Fecundidad -Censo Nacional de población, hogares y viviendas 2022

Algunas visualizaciones útiles

- Gráficos de barras: muestran la frecuencia de cada categoría.
- Gráficos de torta: explican las proporciones relativas.

Gráfico 17. Distribución porcentual de las mujeres en viviendas particulares de 14 a 49 años con y sin hijas e hijos nacidos vivos en el último año, según condición de actividad. Total del país. Año 2022



Fuente: INDEC, Censo Nacional de Población, Hogares y Viviendas 2022. Resultados definitivos.

Exploración de 2 o más variables (juntas)



- Análisis univariado: cómo se comporta cada variable en forma individual.
- Análisis bivariado: método para comparar 2 variables.
- Análisis multivariado: analizar cómo se comportan más de 2 variables.


Exploración de 2 o más variables (visualización)



- Numérica-numérica: Scatterplots, pairplots, matriz de correlación.
- Numérica-categorica: Boxplots, violinplots, etc.
- Categorica-categorica: gráficos de barras y tablas de contingencia (cross-tab).

Análisis bivariado (numérica- numérica)

Pairplot: Scatterplots entre
pares de variables



Análisis multivariado (variables categóricas)

TABLA DE CONTINGENCIA

Cuadro 2.5. Provincia del Chubut. Población en viviendas particulares por sexo, según departamento. Año 2022

Departamento	Total ⁽¹⁾	Sexo		
		Mujer / Femenino	Varón / Masculino	X / Ninguna de las anteriores
Total	599.612	305.364	294.169	79
Biedma	106.092	53.706	52.333	53
Cushamen	28.067	14.196	13.870	1
Escalante	218.520	111.060	107.441	19
Florentino Ameghino	1.792	858	934	-
Futaleufú	50.403	26.247	24.155	1
Gaiman	12.594	6.342	6.252	-
Gastre	1.313	567	745	1
Languiñeo	2.905	1.394	1.510	1
Mártires	746	316	430	-
Paso de Indios	1.877	869	1.008	-
Rawson	146.620	75.848	70.770	2
Río Senguer	6.466	3.097	3.368	1
Sarmiento	14.575	7.203	7.372	-
Tehuelches	5.976	2.889	3.087	-
Telsen	1.666	772	894	-

⁽¹⁾ Incluye la población en situación de calle censada en la vía pública.


Fuente: INDEC, Censo Nacional de Población, Hogares y Viviendas 2022. Resultados provisionales.

Análisis multivariado (variables categóricas)

De todas las muestras de
pingüinos, 124 son de la especie
Gentoo y viven en la isla Biscoe


TABLA DE CONTINGENCIA
REPRESENTADA COMO HEATMAP

Número de pingüinos de cada especie en función de la isla donde habitan




Análisis bivariado (numérica- categórica)

Distribución (KDE) del
largo de la aleta de los
pingüinos para cada
especie





Boxplots del largo de la
aleta para cada especie



Análisis multivariado (numérica-categórica)

Ejemplo:
Pirámides
poblacionales



Fuente: https://www.argentina.gob.ar/sites/default/files/2022/12/08_-_caracterizacion_de_la_migracion_internacional.pdf

Análisis descriptivo

Resumen



EDA variables numéricas



Tendencia central

- 1 Media: valor promedio.
- 2 Mediana: en un conjunto ordenado de números, es el valor que se encuentra en el medio.
- 3 Moda: valor más frecuente.

Dispersión

- 4 Varianza: dispersión de los datos con respecto a la media. Promedia diferencias al cuadrado.
- 5 Desviación estándar: dispersión con respecto a la media pero en las mismas unidades que los datos.
- 6 Cuartiles y rango intercuartil (IQR): otra forma de cuantificar dispersión de los datos.

Forma

- 7 Asimetría (skewness): forma de los datos; qué tan simétrica es la distribución respecto a su media.
- 8 Curtosis: concentración de datos extremos (presencia de colas más pronunciadas o aplanadas).

Medidas basadas en momentos

orden	medida	fórmula	qué información captura
1	media	$\mu = \frac{1}{n} \sum_{i=1}^n x_i$	Centro Es el punto de equilibrio de los datos.
2	varianza	$\sigma^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2$	Dispersión Mide qué tan lejos están los datos de la media.
3	asimetría	$\frac{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^3}{\sigma^3}$	Sesgo Mide si la distribución está sesgada hacia la izquierda o derecha.
4	curtosis	$\frac{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^4}{\sigma^4}$	Extremos y forma Mide la "pesadez" de las colas de la distribución.

EDA variables categóricas



Concentración de categorías

- 1 Moda: valor más frecuente.
- 2 Proporción de la moda: qué proporción del total está representado por la moda.
- 3 Multimodalidad. Permite detectar si la distribución está dominada por una sola categoría.

Distribución y frecuencia

- 4 Frecuencia absoluta: número de veces que aparece cada categoría.
- 5 Frecuencia relativa: Proporción de cada categoría respecto al total de observaciones.
- 6 Rango de frecuencias: diferencia entre la categoría más frecuente y la menos frecuente.

Diversidad o variabilidad

- 7 Cardinalidad: número de categorías únicas.
- 8 Entropía de Shannon: medida de incertidumbre o diversidad de la distribución.

Ejemplos en Python

Revisar la Notebook
clase_02_intro_EDA.ipynb (se encuentra
en la carpeta "notebooks" del repositorio).




Limpieza y preparación de datos

DATA CLEANING

Asegurar la calidad de los datos

Hacemos limpieza de datos para resolver problemas de datos duplicados, formato incorrecto, datos faltantes, datos extremos, entre otros.



DATA WRANGLING

Preparar datos para responder preguntas de análisis

Hacemos esta preparación de datos para resolver inconvenientes relacionados con fuentes de datos diversas, datos irrelevantes, granularidad inadecuada, etc.

Data cleaning


Problema	Cómo se resuelve	con Pandas
Tipos de datos y formato incorrecto	• Conversión	<code>astype()</code> , <code>pd.to_datetime()</code>
Duplicados	• Eliminación	<code>drop_duplicates()</code>
Errores tipográficos o inconsistencias	• Corrección	<code>str.strip()</code> , <code>str.replace()</code>
Valores extremos o anómalos (outliers)	• Eliminación o tratamiento	<code>clip()</code> , <code>quantile()</code>
Valores faltantes	• Rellenar, interpolar, eliminar	<code>fillna()</code> , <code>dropna()</code> , <code>pd.read_csv(na_values=...)</code>

Data wrangling

Problema	Cómo se resuelve	con Pandas
Fuentes de datos diversas	Integración de múltiples fuentes: unir, fusionar, concatenar.	<code>pd.concat()</code> , <code>pd.merge()</code>
Dataset en formato no apropiado	Dar formato según las necesidades.	<code>pivot()</code> , <code>melt()</code> , <code>reset_index()</code>
Categorías inconsistentes	Estandarizar: unificar mayúsculas/minúsculas, corregir abreviaturas, eliminar tildes, definir nomenclaturas únicas.	<code>str.lower()</code> , <code>str.upper()</code> , <code>str.title()</code> , <code>str.strip()</code> , <code>str.replace()</code> , <code>map()</code> , <code>apply()</code>
Datos en formatos no apropiados	Manipular los strings.	<code>split()</code> , <code>extract()</code> , <code>get()</code> , <code>join()</code>
Datos irrelevantes	Filtrar subconjuntos de datos (filas / columnas).	<code>filter()</code> , <code>drop()</code> , <code>loc[]</code>
Datos muy detallados	Agrupar por categorías.	<code>groupby()</code> , <code>agg()</code> , <code>resample()</code>
Datos no explícitos	Enriquecer el dataset mediante la creación de métricas o variables a partir de datos crudos.	<code>assign()</code> , <code>apply()</code> , <code>transform()</code>

Outliers


- Los **outliers** son puntos que difieren significativamente de otras observaciones en un dataset.
- Identificar outliers es crucial porque:
 - indican errores o anomalías en los datos.
 - permiten resaltar hallazgos inusuales pero significativos.
 - pueden afectar a los modelos estadísticos o predictivos, y llevar a interpretaciones o predicciones incorrectas.
- Si no se manejan adecuadamente, los outliers pueden sesgar el análisis y conducir a conclusiones erradas.




Técnicas para detectar outliers

Análisis visual


- Boxplots



- Histogramas




- Scatterplots



Técnicas para detectar outliers

Métodos estadísticos


- datos menores a $(Q1 - 1.5 \cdot IQR)$ o mayores a $(Q3 + 1.5 \cdot IQR)$



Técnicas para detectar outliers

Métodos estadísticos

- datos menores a (media - 3 STD) o mayores a (media + 3 STD)



(asumo distribución normal!)

Datos faltantes ¿qué son?

	F	G	H	I	J
A	0.620576	0.140053	1.352728	NaN	0.808078
B	NaN	0.526829	NaN	NaN	0.170902
C	NaN	0.458827	1.406713	0.071119	NaN
D	NaN	2.307197	NaN	NaN	NaN
E	0.203402	0.259913	NaN	0.505811	1.516755

Missing data

- Son observaciones incompletas o valores no registrados en el dataset (NaN, null).
- Pueden distorsionar el análisis y los modelos si no se tratan (introducir bias y afectar la confiabilidad).

Tipos de causas de datos faltantes

- **MCAR (Missing Completely at Random):** el valor falta por una causa al azar y su falta es independiente de los datos. Es un mecanismo que no introduce sesgo.
- **MAR (Missing at Random):** la falta del valor se relaciona con los datos de otras columnas.
- **MNAR (Missing Not at Random):** la falta depende del dato no observado y se debe a una causa específica que debe ser investigada.



Ejemplo 1

Ejemplo: estamos investigando salarios en Argentina y enviamos una encuesta a 100 personas.

Participante	Edad	Rubro	Salario
1	29	Abogado/a	1.500.000
2	53	Profesor	430.000
3	21	Null	1.350.000
4	34	Analista de marketing	1.000.000
5	Null	A. financiero/a	600.000
5	31	Asesor/a del congreso	700.000
6	48	Recepcionista	770.000
.....			

Los encuestados se olvidaron de responder algunos campos de la encuesta.

MCAR?

Ejemplo 2

Ejemplo: estamos investigando salarios en Argentina y enviamos una encuesta a 100 personas.

Participante	Edad	Rubro	Salario
1	29	Abogado/a	1.500.000
2	37	Profesor/a	430.000
3	53	Analista de datos	Null
4	34	Analista de marketing	1.000.000
5	23	A. financiero/a	600.000
5	31	Asesor/a del congreso	700.000
6	48	Recepcionista	Null
.....			

Los entrevistados mayores de 40 son menos propensos a divulgar su salario.

Hay un patrón, la falta depende de los datos observados (la edad).

MAR?

Ejemplo 3

Ejemplo: estamos investigando salarios en Argentina y enviamos una encuesta a 100 personas.

Participante	Edad	Rubro	Salario
1	45	Abogado/a	Null
2	52	Profesor/a	430.000
3	21	Analista de datos	Null
4	34	Analista de marketing	Null
5	23	A. financiero/a	600.000
5	31	Asesor/a del congreso	700.000
6	48	Recepcionista	770.000
.....			

Las personas con salarios más altos tienden a evitar contestar la pregunta.

La falta depende del dato que no tengo

MNAR?

En definitiva...



- No podemos saber a ciencia cierta qué mecanismo gobierna la falta de datos.
- Con un buen análisis y entendimiento del dominio se pueden hacer hipótesis razonables.

Algunas formas de analizar causas de faltantes

- Métodos gráficos (bibliotecas especiales) para analizar si hay o no patrones.
- EDA - Relaciones entre variables.
- Filtrado / agrupamiento (por ej, es MCAR si el porcentaje de faltantes es aprox. el mismo al agrupar de distintas maneras.
- Tests estadísticos.



Uno más....

Participante	Edad	Año de graduación	Rubro	Salario
1	45	2006	Abogado/a	1.500.000
2	52	1998	Profesor/a	430.000
3	21	Null	Analista de datos	1.350.000
4	34	Null	Analista de marketing	1.000.000
5	23	2024	A. financiero/a	600.000
5	31	2020	Asesor/a del congreso	700.000
6	48	Null	Recepcionista	770.000
.....				

Los faltantes corresponden a personas que no se han graduado

¿Qué podemos decir en este caso?

Falta estructural o por diseño

- Los mecanismos de datos faltantes anteriores implican que el dato debería estar pero por algún motivo no aparece.
- En el caso de la falta por diseño, no es un problema de la recolección de datos. ¡Tiene sentido que el dato no esté!



Ejemplos prácticos en Jupyter



Actividad

- Identificar características generales (por ej. tamaño, tipo de información, curiosidades, desafíos a priori, etc.) del dataset seleccionado para los trabajos prácticos.
- Resumir esta información en 1-2 diapositivas.



En la clase 3, cada grupo tendrá 3 minutos para exponer sus diapositivas.

Peguen [aquí](#) sus slides (fecha límite: jueves 6/11, 14:00 h ARG)

¿Te quedaron dudas?



- Recordá que podés consultarnos durante la clase preniendo la cámara y hablando, o simplemente escribiendo en el chat.
- También podés escribirnos por correo las veces que sea necesario (por favor incluir a ambas docentes).



Esp. Lic. María Carina Roldán
macroldan@fi.uba.ar



Esp. Ing. Ariadna Garmendia
arigarmendia@gmail.com

Y si tenés un feedback, un pedido, una sugerencia, etc. y no te animás a decirlo, podés dejarlo por escrito en la encuesta voluntaria y anónima (disponible durante todo el bimestre).