

Análisis de datos

Carrera de Especialización en
Inteligencia Artificial
B5 2025



Programa de la materia

1 **Introducción al análisis de datos**
23/10 Flujo de trabajo típico. Aplicaciones. Configuración del entorno. Introducción a las principales bibliotecas. Introducción al EDA.

2 **Análisis exploratorio de datos (EDA)**
30/10 EDA. Estadística robusta. Visualización de variables numéricas y categóricas. Relación entre variables. Data cleaning y data wrangling. Identificación de valores faltantes y outliers.

3 **Taller práctico - parte 1**
6/11 Presentación de grupos de trabajo final. Práctica en salas virtuales: EDA y visualización inicial de un dataset. Puesta en común.

4 **Preprocesamiento y limpieza de datos**
13/11 Prevención de data leakage. Tratamiento de datos faltantes. Tratamiento de outliers.

5 **Feature engineering**
20/11 Cardinalidad, codificación, discretización. Desbalance. Creación de nuevos features. Normalización y estandarización.

6 **Reducción de dimensionalidad**
27/11 Métodos de extracción y técnicas para selección de features. **Bonus:** EDA de datos no estructurados.

7 **Taller práctico - parte 2**
4/12 Práctica en salas virtuales: preprocesamiento y feature engineering de un dataset. Puesta en común. **Bonus:** Herramientas para automatizar el EDA.



Martes 9/12 - límite para compartir el material para la exposición final.

8 **Exposición final**
11/12 Exposición de trabajos finales (desdoblada en 2 sesiones, 11/12 y 15/12).

Agenda para hoy

- Presentaciones de cada grupo (7 - 7:55 pm)
- Recreo (7:55 - 8:05 pm)
- Recap de lo visto en la clase 2 (8:05 - 8:25 pm)
- Recreo (8:25 - 8:30 pm)
- Taller práctico en salas virtuales (8:30 - 10 pm)



Actividad

Cada grupo tendrá 3 minutos para exponer:

- Características generales identificadas (por ej. tamaño, tipo de información, curiosidades, desafíos a priori, etc.) del dataset seleccionado para el trabajo práctico.



Recap de lo visto en la clase 2






EDA




- Las métricas descriptivas permiten estimar las características de una variable aleatoria utilizando una muestra de datos.

Variables numéricas

Tendencia central






Forma



Dispersión

varianza y desvío estándar



asimetría

Variables categóricas

Concentración


- Moda
- Proporción de la moda
- Multimodalidad

Distribución y frecuencia

- Frecuencia absoluta
- Frecuencia relativa
- Rango de frecuencias

Diversidad o variabilidad

- Cardinalidad
- Entropía de Shannon



Datos faltantes

- Son observaciones incompletas o valores no registrados en el dataset (NaN, null).




Tipos de faltantes

- MCAR (Missing Completely at Random)
- MAR (Missing at Random)
- MNAR (Missing Not at Random)
- Mecanismo estructural o por diseño.

Técnicas para analizar faltantes

Análisis visual

- bibliotecas especiales



Otros

- EDA (relaciones)
- Filtrado / agrupamiento
por ej, es MCAR si el porcentaje de faltantes es aprox. el mismo al agrupar de distintas maneras.
- Tests estadísticos.


Outliers

- Son puntos que difieren significativamente de otras observaciones en un dataset.


Técnicas para detectar outliers

Análisis visual

- Boxplots




- Histogramas




Métodos estadísticos

- datos menores a $(Q1 - 1.5 \cdot IQR)$ o mayores a $(Q3 + 1.5 \cdot IQR)$



- datos menores a $(media - 3 \text{ STD})$ o mayores a $(media + 3 \text{ STD})$



Taller práctico (parte 1)



Estadísticas climáticas



Servicio
Meteorológico
Nacional
Argentina

Estadísticas climáticas

- Entre todos vamos a realizar el EDA y visualizaciones de datos del Servicio Meteorológico Nacional Argentino.
- El dataset contiene datos abiertos con estadísticas climáticas normales para el período 1991-2020.



Terminología básica

para entender los datos

Estaciones meteorológicas

Corresponden a los sitios donde se miden y registran las condiciones del tiempo atmosférico de manera sistemática y continua.

Estadísticas climáticas normales

Se le llama así a los valores promedio y extremos de diferentes variables meteorológicas, calculados sobre un período estándar de 30 años. Sirven como referencia climatológica.



El dataset

Estadísticas climáticas normales calculadas sobre el período 1991-2020 para todas las estaciones meteorológicas del país.

Las variables registradas son:

- temperatura media, máxima y mínima
- humedad relativa
- velocidad del viento
- nubosidad total
- precipitación
- frecuencia de días con precipitación superior a 0,1 mm.




Actividad

- Vamos a trabajar en salas.
- Cada sala tendrá asignada una tarea diferente.
- En la carpeta recursos del repositorio tienen notebooks para cada grupo:

- salas-1-2-3-taller.ipynb
- salas-4-5-6-taller.ipynb
- salas-7-8-9-taller.ipynb



- Tendrán 40 minutos para realizar la consigna.
- Al finalizar haremos una puesta en común.



SALAS

1, 2, 3



Realizar un análisis exploratorio de datos (EDA) de los datos provistos.

SALAS

4, 5, 6



A partir de los datos provistos, identificar nulos y analizar posibles causas.

SALAS

7, 8, 9



A partir de los datos provistos, identificar outliers. ¿Consideran que son legítimos o que son errores?

¿Te quedaron dudas?



- Recordá que podés consultarnos durante la clase preniendo la cámara y hablando, o simplemente escribiendo en el chat.
- También podés escribirnos por correo las veces que sea necesario (por favor incluir a ambas docentes).



Esp. Lic. María Carina Roldán
macroldan@fi.uba.ar



Esp. Ing. Ariadna Garmendia
arigarmendia@gmail.com

Y si tenés un feedback, un pedido, una sugerencia, etc. y no te animás a decirlo, podés dejarlo por escrito en la encuesta voluntaria y anónima (disponible durante todo el bimestre).