

Análisis de datos

Carrera de Especialización en
Inteligencia Artificial
B5 2025



Programa de la materia

1 **Introducción al análisis de datos**
23/10 Flujo de trabajo típico. Aplicaciones. Configuración del entorno. Introducción a las principales bibliotecas. Introducción al EDA.

2 **Análisis exploratorio de datos (EDA)**
30/10 EDA. Estadística robusta. Visualización de variables numéricas y categóricas. Relación entre variables. Data cleaning y data wrangling. Identificación de valores faltantes y outliers.

3 **Taller práctico - parte 1**
6/11 Presentación de grupos de trabajo final. Práctica en salas virtuales: EDA y visualización inicial de un dataset. Puesta en común.

4 **Preprocesamiento y limpieza de datos**
13/11 Flujo de preparación de datos. Prevención de data leakage. Tratamiento de datos faltantes y outliers. Cardinalidad. Codificación. Discretización.

5 **Procesamiento (continuación)**
20/11 Normalización y estandarización. Técnicas avanzadas para el tratamiento de datos faltantes y outliers. Desbalance. Creación de nuevos features.

6 **Reducción de dimensionalidad**
27/11 Métodos de extracción y técnicas para selección de features. **Bonus:** EDA de datos no estructurados.

7 **Taller práctico - parte 2**
4/12 Práctica en salas virtuales: preprocesamiento y feature engineering de un dataset. Puesta en común. **Bonus:** Herramientas para automatizar el EDA.




Martes 9/12 - límite para compartir el material para la exposición final.

8 **Exposición final**
11/12 (desdoblada en 2 sesiones, 11/12 y 15/12). Exposición de trabajos finales

Flujo de trabajo del análisis de datos para IA



Flujo de preparación de datos para IA



Data leakage

Es un problema que sucede cuando cierta información que no se suponía que el modelo debía conocer, se filtra al momento del entrenamiento.



Como resultado, al evaluar el modelo se obtienen métricas de desempeño engañosas (demasiado optimistas) y mala performance con datos nuevos.

Tipos de data leakage

- Target leakage: se entrena el modelo con datos que no estarían disponibles en un escenario real.
- Contaminación train-test: se entrena el modelo con información de los datos de test (usualmente ocurre al preprocesar los datos).



Ejemplo: target leakage

Una empresa de celulares quiere usar IA para predecir cuántos clientes se perderán este año.

Para entrenar el modelo, el equipo utiliza las siguientes variables:

`id_cliente`, `fecha_alta`,
`servicio contratado`, `deuda`,
`nro_reclamos` y `fecha_baja`.



Ejemplo: contaminación train-test

Un profesor está entrenando a un grupo de alumnos en estadística y quiere evaluar cuánto aprendieron.

En el examen, les toma 5 ejercicios pero 3 de ellos son exactamente iguales a los vistos en la práctica.



Trucos para evitar data leakage

- Prevenir target leakage:
 - Analizar los features disponibles. Evitar incluir features que conducen directamente a la variable target o que no estarían disponibles en un escenario real.
 - Cuidado al dividir en train y test, por ejemplo, no incluir datos futuros.
- Prevenir contaminación train-test:
 - Realizar el split antes de cualquier preprocesamiento. Calcular las transformaciones sobre los datos de entrenamiento únicamente, y luego aplicarlas a los datos de test. Tener cuidado con los duplicados!



Consideraciones al hacer el split

x1	x2	target
01/2024		
...		
...		
04/2024		
...		
...		
09/2024		
10/2024		
...		
12/2024		

SERIE TEMPORAL

x1	x2	target
CLIENTE 1		
CLIENTE 1		
CLIENTE 1		
CLIENTE 2		
CLIENTE 2		
CLIENTE 3		
CLIENTE 3		
CLIENTE 4		
CLIENTE 4		
CLIENTE 5		

CLUSTERS DE DATOS
(El dataset contiene múltiples
muestras de la misma entidad:
clientes, pacientes, etc.)

TRAIN

TEST

Estrategias para manejo de datos faltantes y outliers


¿qué son los datos faltantes?

	F	G	H	I	J
A	0.620576	0.140053	1.352728	NaN	0.808078
B	NaN	0.526829	NaN	NaN	0.170902
C	NaN	0.458827	1.406713	0.071119	NaN
D	NaN	2.307197	NaN	NaN	NaN
E	0.203402	0.259913	NaN	0.505811	1.516755

Missing data

Son observaciones incompletas o valores no registrados en el dataset (NaN, null).

¿qué son los outliers?



Son puntos que difieren significativamente de otras observaciones en un dataset.

Si no se manejan adecuadamente, los datos faltantes y los outliers pueden distorsionar el análisis, introducir sesgo en los modelos y conducir a conclusiones erradas.

Estrategias para manejo de datos faltantes



Eliminación:

- Borrar filas (observaciones).
- Borrar columnas (variables).

Imputación (colocar un valor):

- Métodos *univariados* (se usan los datos de la variable con faltantes).
 - Por media, mediana, moda.
 - Valor de adelante o de atrás.
 - Crear nueva categoría.
 - Series temporales: hacia adelante/atrás e interpolación lineal o polinómica.

Ejemplo: imputación por la mediana



columna original

Imputación

Mediana de la
edad = 28

sex	fare	class	deck	embark_town	alive	alone	age	age_2
male	26.5500	First	E	Southampton	yes	True	51.00	51.00
female	21.0750	Third	NaN	Southampton	no	False	3.00	3.00
female	19.2583	Third	NaN	Cherbourg	yes	False	0.75	0.75
male	7.2292	Third	NaN	Cherbourg	no	True	NaN	28.00
male	8.0500	Third	NaN	Southampton	no	True	34.00	34.00
female	23.0000	Second	NaN	Southampton	yes	False	18.00	18.00
female	27.7208	First	B	Cherbourg	yes	True	44.00	44.00
male	14.5000	Third	NaN	Southampton	no	True	NaN	28.00
male	9.5000	Third	NaN	Southampton	no	True	NaN	28.00
female	9.5875	Third	NaN	Southampton	no	True	37.00	37.00
male	11.5000	Second	NaN	Southampton	no	False	21.00	21.00
male	78.8500	First	C	Southampton	no	False	36.00	36.00

Histograma de la edad antes y
después de la imputación




Ejemplo: imputación hacia adelante/atrás

columna original

Imputación

	date	passengers	pass_ffill	pass_bfill
0	1949-01-01	NaN	NaN	118.0
1	1949-02-01	118.0	118.0	118.0
2	1949-03-01	132.0	132.0	132.0
3	1949-04-01	129.0	129.0	129.0
4	1949-05-01	NaN	129.0	135.0
5	1949-06-01	135.0	135.0	135.0
6	1949-07-01	148.0	148.0	148.0
7	1949-08-01	148.0	148.0	148.0
8	1949-09-01	136.0	136.0	136.0
9	1949-10-01	119.0	119.0	119.0
10	1949-11-01	NaN	119.0	126.0
11	1949-12-01	NaN	119.0	126.0
12	1950-01-01	NaN	119.0	126.0
13	1950-02-01	126.0	126.0	126.0

Número de pasajeros antes y después de la imputación



¿Cómo elegir la estrategia para el tratamiento de faltantes? 1/2

- Si los faltantes son MCAR:
 - Eliminación de fila cuando los datos faltantes representan 5-10% máx. del total de filas.
 - Eliminación de columna: >60-70% valores faltantes en la misma columna y la variable no es importante.
 - Atención: evaluar el impacto en la distribución de los datos antes de eliminar filas. Eliminar datos puede producir sesgo.
- Si son MCAR o MAR y el porcentaje de faltantes es bajo (10-30%):
 - Imputación por media: datos con distribución aprox. Normal.
 - Imputación por mediana (captura mejor relaciones no lineales pero depende de la calidad de otras variables y puede implicar más costo computacional).
 - Imputación por moda (variables categóricas) o nueva categoría (ej., "FALTANTE") si tiene sentido.
 - Atención: imputar con la media, mediana y moda modifican la varianza.

¿Cómo elegir la estrategia para el tratamiento de faltantes? 2/2

- Si son MAR con patrones claros y el porcentaje es moderado a alto (20-50%)
 - Técnicas avanzadas (las veremos más adelante)
- Si se sospecha de MNAR o MAR complejos (dependen de muchas variables):
 - Técnicas avanzadas (las veremos más adelante)
- Series temporales:
 - se elige una imputación específica según el tipo de serie (interpolación, modelos de series temporales como ARIMA, LSTMs, modelos generativos).

Estrategias para manejo de outliers

- **Eliminación.**
 - Si no son representativos o se los considera errores.
 - **Imputación.**
 - Reemplazar por un valor acorde (media, mediana).
 - Aplicar winsorización (o *capping* en inglés): reemplazar por un valor máximo o mínimo definido, generalmente basado en un percentil.
 - **Transformación** (Para minimizar el impacto)
 - Logarítmica (o raíz cuadrada)
 - **Segmentación.**
 - Agrupar los outliers en una categoría separada (variables categóricas)
- Analizar si se trata de errores o son valores legítimos!

Ejemplos prácticos en Jupyter



Cardinalidad (v. categóricas)

Es el número de valores únicos que puede tomar una variable en un conjunto de datos.

Baja

La mayoría de los valores se repiten



Estado civil

Día de la semana

Alta

Muchos valores únicos



Nombres de clientes

Direcciones de correo electrónico

Extrema

Cada valor es único en la mayoría de los casos.



Números de serie

Códigos de transacciones

Codificación

- Consiste en transformar **variables categóricas** en **números** para que puedan ser utilizadas por algoritmos de ML.
- La elección de la estrategia de codificación depende fuertemente de la **cardinalidad** de los datos.



Estrategias de codificación

...	COLOR	...	PRECIO
...	AZUL	...	8
...	ROJO	...	10
...	VERDE	...	5
...	AZUL	...	16
...	VERDE	...	7
...	VERDE	...	3

One-hot

AZUL	ROJO	VERDE
1	0	0
0	1	0
0	0	1
1	0	0
0	0	1
0	0	1

Label

COLOR_L
10
20
30
10
30
30

Ordinal

COLOR_O
0
1
2
0
2
2

Estrategias de codificación

¿Estamos ante un caso de data leakage?



...	COLOR	...	PRECIO
...	AZUL	...	8
...	ROJO	...	10
...	VERDE	...	5
...	AZUL	...	16
...	VERDE	...	7
...	VERDE	...	3

Target

COLOR_T
12
10
5
12
5
5

$$\text{Azul} = (8 + 16) / 2 = 12$$

$$\text{Rojo} = (10) / 1 = 10$$

$$\text{Verde} = (5 + 7 + 3) / 3 = 5$$

Estrategias de codificación

¿Estamos ante un caso de data leakage?



...	COLOR	...	PRECIO
...	AZUL	...	8
...	ROJO	...	10
...	VERDE	...	5
...	AZUL	...	16
...	VERDE	...	7
...	VERDE	...	3

Target

COLOR_T
12
10
5
12
5
5

Para reducir el data leakage se puede implementar una variante:

k-fold target encoding

o

leave-one-out target encoding

[Video](#)

Estrategias de codificación

...	COLOR	...	PRECIO
...	AZUL	...	8
...	ROJO	...	10
...	VERDE	...	5
...	AZUL	...	16
...	VERDE	...	7
...	VERDE	...	3

Target

COLOR_T
12
10
5
12
5
5

Frequency

COLOR_F
0.333
0.166
0.5
0.333
0.5
0.5

$$\text{Azul} = 2/6 = 0.333$$

$$\text{Rojo} = 1/6 = 0.166$$

$$\text{Verde} = 3/6 = 0.5$$

Estrategias de codificación

...	COLOR	...	PRECIO
...	AZUL	...	8
...	ROJO	...	10
...	VERDE	...	5
...	AZUL	...	16
...	VERDE	...	7
...	VERDE	...	3

Target

COLOR_T
12
10
5
12
5
5

Frequency

COLOR_F
0.333
0.166
0.5
0.333
0.5
0.5

Hashing

H1	H2
0	1
1	0
1	1
0	1
1	1
1	1

Hashing encoding: aclaraciones

- En general es la solución preferida cuando se tienen variables categóricas con cardinalidad muy alta y se trabaja con pipelines simples y modelos de ML tradicional.
- Los enfoques híbridos con *embeddings** pre-entrenados son una alternativa, pero implican mayor complejidad. Por lo general se usan para capturar semejanzas semánticas entre categorías.


ID_EMPL	TITULO	SUELDO
E00001	MACHINE LEARNING ENGINEER	...
E00002	SENIOR SOFTWARE DEVELOPER	...
E00003	ANALISTA DE RECURSOS HUMANOS	...
...	...	...

(*) *Embeddings* se explica en detalle en la materia Aprendizaje Profundo.

Estrategias de codificación

date	month	month_num	month_sin	month_cos
1949-01-01	Jan	1	0.5000	0.8660
1949-02-01	Feb	2	0.8660	0.5000
1949-03-01	Mar	3	1.0000	0.0000
1949-04-01	Apr	4	0.8660	-0.5000
1949-05-01	May	5	0.5000	-0.8660
1949-06-01	Jun	6	0.0000	-1.0000
1949-07-01	Jul	7	-0.5000	-0.8660
1949-08-01	Aug	8	-0.8660	-0.5000
1949-09-01	Sep	9	-1.0000	-0.0000
1949-10-01	Oct	10	-0.8660	0.5000
1949-11-01	Nov	11	-0.5000	0.8660
1949-12-01	Dec	12	-0.0000	1.0000
1950-01-01	Jan	1	0.5000	0.8660
1950-02-01	Feb	2	0.8660	0.5000
1950-03-01	Mar	3	1.0000	0.0000

Cyclic encoding



Ejemplos prácticos en Jupyter



RESUMEN de estrategias de codificación

Técnica	Consiste en ...	Ideal para...
One-Hot Encoding	crear una columna binaria (0/1) para cada categoría.	Baja cardinalidad. Multi-label (multi-hot encoding)
Label Encoding	asignar un número entero arbitrario a cada categoría	Codificar la variable target
Ordinal Encoding	asignar un número entero secuencial a cada categoría.	Variables con un orden lógico
Target Encoding	reemplazar cada categoría con la media (u otra estadística) de la variable objetivo.	Alta cardinalidad. Problemas supervisados
Frequency Encoding	sustituir cada categoría por su frecuencia de aparición.	Muchas categorías frecuentes (si hay categorías poco frecuentes, agrupar). Hay relación fuerte entre la frecuencia de una categoría y la variable target (ej. fraude)
Hashing Encoding	aplicar una función hash para mapear categorías en un número fijo de dimensiones.	Cardinalidad extrema
Cyclic Encoding	transformar variables cíclicas en coordenadas en un círculo mediante funciones seno y coseno.	Variables con patrón cíclico


Estrategias de codificación. Ventajas y desventajas.

Técnica	Ventajas	Desventajas
One-Hot Encoding	Simple y efectiva	Escala mal con alta cardinalidad
Label encoding	Simple y efectiva	Pensado únicamente para la variable target (porque implica orden)
Ordinal Encoding	Conserva el orden natural	Crea relaciones numéricas artificiales, (lineal, igualmente espaciada, por ej: low=1, medium=2, high=3) y puede confundir a los modelos lineales o basados en distancia
Target Encoding	Compacto y efectivo	Riesgo de sobreajuste
Frequency Encoding	Útil para reducir categorías raras	Puede perder información
Hashing Encoding	Escalable y eficiente	Puede provocar colisiones (no es reversible) No conserva relaciones semánticas, orden ni jerarquía
Cyclic Encoding	Conserva continuidad temporal	No se recomienda en datos sin periodicidad clara


Discretización

- La discretización convierte **variables continuas** en variables discretas o **categorías**.
- Se usa para mejorar la interpretación o el rendimiento de un modelo.

Métodos de discretización




- Por intervalos de igual rango de valores.



- Por puntos de corte (cuantiles)

¿Por qué discretizamos?



- Para reducir la cantidad de datos y la complejidad computacional.
- Con el objetivo de disminuir el “ruido”: muchas veces los datos crudos incluyen fluctuaciones aleatorias o irrelevantes que contribuyen al overfitting.
- Cuando se requiere convertir una variable continua en categórica (ej: adaptar la variable target para clasificación).
- Para mejorar el entendimiento o la interpretación de un problema (por ejemplo, convertir edades de clientes en segmentos objetivo: joven, adulto, adulto mayor).
- Como herramienta para “contener” el efecto de los outliers.

Ejemplos prácticos en Jupyter



RESUMEN de métodos de discretización

Método	Descripción	Pros y contras
Intervalos iguales	Rangos de igual amplitud.	Simple. No sirve si los datos son asimétricos.
por puntos de corte	Basados en la distribución de los datos. Cada intervalo tiene el mismo número de observaciones.	Funciona bien para datos asimétricos.
K-means	Agrupar los datos en clusters con el algoritmo k-means	Captura agrupamientos naturales. Para datasets grandes requiere mucho cómputo.
Ancho fijo	Definidos por el usuario basados en el conocimiento del dominio.	Control total, pero requiere conocimiento de los datos y su distribución.

¿Te quedaron dudas?



- Recordá que podés consultarnos durante la clase preniendo la cámara y hablando, o simplemente escribiendo en el chat.
- También podés escribirnos por correo las veces que sea necesario (por favor incluir a ambas docentes).



Esp. Lic. María Carina Roldán
macroldan@fi.uba.ar



Esp. Ing. Ariadna Garmendia
arigarmendia@gmail.com

Y si tenés un feedback, un pedido, una sugerencia, etc. y no te animás a decirlo, podés dejarlo por escrito en la encuesta voluntaria y anónima (disponible durante todo el bimestre).